

**Profesor:** Héctor Bahamonde.

**e:** [hector.bahamonde@uoh.cl](mailto:hector.bahamonde@uoh.cl)

**w:** [www.hectorbahamonde.com](http://www.hectorbahamonde.com)

**Curso:** Métodos Cuantitativos I.

## REGRESSION DISCONTINUITY DESIGNS (RDDs)—SHARP DESIGNS

La idea de este método es poder imitar RCTs (*randomized control trials*). Su foco es poder imitar la asignación aleatoria de un tratamiento experimental, particularmente, en lo que respecta a la construcción “**teórica**” de un grupo *pre-treatment* y otro *post-treatment*. Sin embargo, la asignación a tratamiento *no* es aleatoria, si no que depende de otras variables.

Imagina el siguiente problema. Supongamos que queremos saber el efecto que tuvo una política pública. Qué herramientas econométricas podrías usar para simular un efecto causal del tratamiento?

Partiremos pensando en una ecuación lineal, donde nuevamente  $z$  es nuestro (cuasi) tratamiento. La variable  $z$  es binaria  $[0, 1]$  y representa si la observación  $i$  fue tratada  $z(1)$  o no  $z(0)$ . Como en todos los supuestos de la inferencia causal, el promedio de los **observables** de  $i(1)$  y  $i(0)$  son iguales. Veamos la ecuación:

$$y_i = \beta_0 + \beta_1 x_i + \pi z_i + \rho x_i z_i + \epsilon_i \quad (1)$$

donde  $y$  es la variable dependiente,  $\beta_0$  es el intercepto y  $\epsilon_i$  es el residuo para la observación  $i$ . Además,  $\beta_1$  es el efecto asociado a cierta variable de control  $x$ . Importantemente, existen dos maneras de ver (cuasi) causalidad en [Equation 1](#):

1. **“Cambio en el intercepto”**: Se observa al ver el efecto y significancia de  $\pi$  que es el parámetro a estimar asociado al tratamiento  $z$ .
2. **“Cambio en el slope/pendiente”**: este se observa al ver el parámetro  $\rho$  que representa al efecto estimado *combinado* de la variable tratamiento  $z$  y la variable control  $x$ . Matemáticamente, esto significa que tendremos un parámetro asociado a un **término de interacción** de la siguiente forma:  $\rho(x_i \times z_i)$ .

### Términos de Interacción

Se usan cuando queremos saber el efecto combinado de dos variables. Por ejemplo, si quisiéramos saber cuál es el efecto que tiene *género* ( $x_1$ ) y (esto es, en **combinación con**) *educación* ( $x_2$ ) sobre *ingresos* ( $y_i$ ), deberíamos estimar la siguiente ecuación:

$$\text{ingresos}_i = \beta_0 + \beta_1 \text{género}_i + \beta_2 \text{educación}_i + \beta_3 \text{género}_i \times \text{educación}_i + \epsilon_i \quad (2)$$

Fíjate que cada vez que incluimos un término de interacción ( $\text{género}_i \times \text{educación}_i$ ), para interpretar su parámetro asociado ( $\beta_3$ ), es necesario incluir los sub-términos por separados. Esto es, permitir que la ecuación tenga un parámetro independiente asociado a *género* y *educación*, esto es,  $\beta_1$  y  $\beta_2$  (tal y como aparece en [Equation 2](#)). Si estimamos sólo la siguiente ecuación,  $\beta_3$  estará sesgado. **NO HAGAS LO SIGUIENTE**:

$$\text{ingresos}_i = \beta_0 + \beta_3 \text{género}_i \times \text{educación}_i + \epsilon_i \quad (3)$$

Debido a que los efectos (cuasi) causales en los RDDs son (matemáticamente hablando) términos de interacción, era necesario saber qué es lo que eran. Ahora que sabemos lo que es un término de interacción, volvamos a los RDD y sus supuestos.

### Supuestos

1. **Criterio de corte.** Es importante tomar en cuenta que  $z$  **no** está asignado aleatoriamente. En otras palabras, la **discontinuidad** que pudiera existir en  $x$  *no* es debido a  $z$ , sino que **solamente** a  $x$ —y este es el supuesto. Esto no es precisamente una desventaja. Al contrario, te permite evaluar el efecto de  $x$  sobre  $y$  en dos grupos distintos ( $y(1)$  y  $y(0)$ ). En un experimento propiamente tal,  $z$  siempre es aleatorio. En nuestro mundo observacional, sin embargo, esto no es el caso.
2. **La relación entre  $x$  e  $y$  no es mejor explicada por una función polinomial** (Fig. 6.1.1 en *Mostly Harmless Econometrics*). El “salto” que se produce en  $y$  al cambiar de  $z(0)$  a  $z(1)$  es mejor explicado por  $z$  mismo que por ejemplo, una función polinomial. Esto es, con interacciones, tal y como en [Equation 2](#), pero esta vez, la variable es multiplicada por sí misma (como en [Equation 4](#)). Un ejemplo de una regresión polinomial permite curvas en la línea, y en general se ven así:

$$y_i = \beta_0 + \beta_1 x_i + \beta_2 (x_i)^2 \epsilon_i \quad (4)$$

3. **La variable  $x$  es continua.**

### Preparación

Si todos estos supuestos se cumplen, debemos seguir los siguientes pasos:

1. **Transformar los datos.** Más formalmente, esto quiere decir que debemos manipular  $x$ . En otras palabras, debemos acercar la distribución hacia el eje Y—hacia el intercepto. Esto se hace mediante la siguiente sustracción:  $x_i - x_{\text{corte}}$ . De esta manera, cualquier efecto (cuasi) causal se observará respecto al “alejamiento” del eje Y (es decir, del intercepto).
2. **Convertir  $z$  en una dummy [0,1].**
3. **Inspección visual** entre  $x$ ,  $y$  y  $z$ . *Plotear* distribuciones.
4. **Estimar modelo general [Equation 1](#).**

### Estimación

Realizando estos pasos, deberemos estimar la siguiente ecuación:

$$y_i = \beta_0 + \beta_1 (x_i - x_{\text{corte}}) + \pi z_i + \rho_2 (x_i - x_{\text{corte}}) \times z_i + \epsilon_i \quad (5)$$

Realizaremos este modelo general en los siguientes ejercicios.

**Group 2: “Cambio en el intercepto” ( $\pi$ )** . Si te fijas, contiene dos resultados diferentes (que se pueden ver en el output de R). La siguiente ecuación nos muestra un resultado para  $z(1)$  y otro para  $z(0)$ .

$$\begin{aligned} y_i &= \beta_0 + \beta_1(x_i - x_{\text{corte}}) + \pi(0) + \rho_2(x_i - x_{\text{corte}}) \times 0 + \epsilon_i \\ y_i &= \beta_0 + \beta_1(x_i - x_{\text{corte}}) + \pi(1) + \rho_2(x_i - x_{\text{corte}}) \times 1 + \epsilon_i \end{aligned} \quad (6)$$

lo que en números significa,

$$\begin{aligned} y_i(0) &= 50.77 + 3.46(x_i - 10.5) + \cancel{5.50 \times (0)} + \cancel{1.86(x_i - 10.5) \times (0)} + \epsilon_i \\ y_i(1) &= 50.77 + 3.46(x_i - 10.5) + 5.50 \times (1) + 1.86(x_i - 10.5) \times (1) + \epsilon_i \end{aligned} \quad (7)$$

Y si seguimos desarrollando la ecuación Equation 7 pero sólo para  $z(1)$ , tendríamos:

$$\begin{aligned} y_i(1) &= 50.77 + 3.46(x_i - 10.5) + 5.50 + 1.86(x_i - 10.5) + \epsilon_i \\ y_i(1) &= (50.77 + 5.50) + 3.46(x_i - 10.5) + 1.86(x_i - 10.5) + \epsilon_i \\ y_i(1) &= 56.27 + 5.32(x_i - 10.5) + \epsilon_i \end{aligned} \quad (8)$$

Es claro ver que Equation 7 nos muestra el pre-treatment  $z(0)$  y el post-treatment  $z(1)$ . Y eso se ve reflejado en el output de R. Es importante que entiendas que matemáticamente el efecto asociado a  $z$  (esto es,  $\rho$ ), es una multiplicación entre  $x_i$  y  $z$ .

**Group 3: “Interaction Effect” ( $\rho$ )** . Otra manera de ver el efecto (cuasi) causal de Equation 1, es observar el parámetro  $\rho$  que está asociado al término de interacción ( $x_i \times z_i$ ).

Por Qué Esta Técnica Es (Cuasi) Experimental?

1. Observaciones no saben con anticipación dónde será el corte.
2. **Supuesto de exogeneidad de  $z$  a medida que nos acercamos al corte en  $x$ .** Similitud de características observables en  $x$ . Pero pérdida de eficiencia estadística.

Sharp y Fuzzy Designs

En esta ocasión hemos visto “*sharp*” designs. Estos diseños asumen “*perfect compliance*”: al cambiar de  $z(0)$  a  $z(1)$ , no existe overlap entre observaciones a lo largo de  $x$ . Substantivamente, esto significa que la variable  $z$  clasifica *perfectamente* a las observaciones a lo largo de  $x$ , lo que en la realidad no siempre es así.

Queda pendiente para la siguiente iteración de este curso:

1. *Fuzzy designs, average treatment among the treatments (ATT, que se usa en sharp designs), intention to treat y local average treatment effects (LATE), que se usan en fuzzy designs.*